Highlights

Los índices de robustez premian las planificaciones nominales deficientes: una auditoría de medición de la programación dinámica de talleres bajo perturbación

Joseph Javier Sánchez Acuña

- Se demuestra que el índice de robustez convencional es una función estrictamente decreciente de la desviación nominal a desempeño realizado fijo.
- Correlaciona con la desviación nominal en los nueve regímenes de perturbación, con $\rho_s = -0{,}95$ a $-0{,}98$ donde se comparan diez métodos: peores planificaciones nominales puntúan como más robustas.
- El orden por el índice contradice el orden por calidad realizada en los nueve regímenes, con un costo de hasta 49,3 puntos porcentuales.
- La calidad realizada frente a un óptimo certificado, más una cola CVaR_{90}, restablece la comparabilidad entre métodos sin nuevos experimentos.
- Bajo la métrica corregida, una política GNN–PPO iguala al mejor comparador en todos los regímenes y ocupa el primer lugar en cinco, incluidos los de llegadas.

Los índices de robustez premian las planificaciones nominales deficientes: una auditoría de medición de la programación dinámica de talleres bajo perturbación

Joseph Javier Sánchez Acuña[a,*]

[a] *Universidad de los Andes, Bogotá, Colombia*

ARTICLE INFO

Palabras clave:
Programación dinámica de talleres
Medición de robustez
Aprendizaje por refuerzo profundo
Redes neuronales de grafos
Programación con restricciones
Metodología experimental

Resumen

El aprendizaje por refuerzo profundo (DRL) se propone cada vez con más frecuencia para la programación dinámica de talleres bajo el argumento de que las políticas de despacho aprendidas son más *robustas* ante la perturbación que la optimización fuera de línea. Esa afirmación se sostiene casi siempre sobre un índice de robustez de la forma $\mathrm{RI} = (\mathbb{E}[C^{\mathrm{pert}}_{\mathrm{máx}}] - C^{\mathrm{nom}}_{\mathrm{máx}})/C^{\mathrm{nom}}_{\mathrm{máx}}$, que normaliza la degradación que sufre un método por su propio makespan sin perturbar. Mostramos, analítica y empíricamente, que esa normalización autorreferencial vuelve el índice inservible para comparar métodos. Escribiendo r y q para las desviaciones relativas del makespan nominal y del realizado respecto de un óptimo certificado, demostramos que $\mathrm{RI} = (q - r)/(1 + r)$, de modo que a igual desempeño realizado RI es estrictamente decreciente en r: cuanto peor es la planificación nominal de un método, más robusto parece. En un corpus de 4,500 ejecuciones perturbadas que abarca 9 regímenes preregistrados de tres clases de perturbación, RI correlaciona por rangos de forma negativa con la desviación nominal en todos los regímenes, con ρ_s entre $-0{,}985$ y $-0{,}948$ ($p \leq 3 \times 10^{-5}$) en los 6 regímenes que comparan diez métodos, y el orden que induce discrepa del orden por calidad realizada en los 9 (τ de Kendall negativo sin excepción). Elegir un programador por RI en lugar de por calidad realizada cuesta entre 15.8 y 49.3 puntos porcentuales de desviación respecto del óptimo (mediana 25.7). Proponemos la calidad realizada — la desviación del makespan ejecutado respecto del óptimo certificado — junto con su cola CVaR_{90}, y una disciplina de reporte de tres comparadores que separa la regla media, la mejor regla por familia y el oráculo por instancia. Remedida así, una política PPO sobre red neuronal de grafos heterogénea resulta estadísticamente indistinguible del mejor comparador en los 9 regímenes y ocupa el primer lugar en 5, incluidos los tres de llegadas dinámicas: una conclusión que el índice convencional invierte.

1. Introducción

Las planificaciones de producción se calculan bajo supuestos que la planta no respeta. Las máquinas fallan, los tiempos de proceso se realizan lejos de sus estimaciones y llegan trabajos después de que la planificación quedó fijada. La literatura ha respondido con dos estrategias amplias: calcular una planificación fuera de línea y repararla conforme ocurren los eventos, o aprender una política de despacho que decide en línea y que, por tanto, nunca se compromete con una secuencia que después deba abandonar (Ouelhadj and Petrovic, 2009; Aytug, Lawley, McKay, Mohan and Uzsoy, 2005). La segunda ha concentrado un interés reciente intenso, con redes neuronales de grafos aportando una representación de estado agnóstica al tamaño y métodos de gradiente de política aportando la señal de aprendizaje (Zhang, Song, Cao, Zhang, Tan and Xu, 2020; Park, Chun, Kim, Kim and Park, 2021; Song, Chen, Li and Cao, 2023; Bengio, Lodi and Prouvost, 2021).

El argumento empírico a favor de las políticas aprendidas descansa sobre una afirmación de robustez. Se sostiene que una política aprendida se degrada menos bajo perturbación que un óptimo fuera de línea, y esto se cuantifica mediante un índice que compara el makespan perturbado de un método con su propio

*Autor de correspondencia.
joseph.sanchez@uniminuto.edu.co (J.J.S. Acuña)

makespan sin perturbar:

$$\mathrm{RI} \;=\; \frac{\mathbb{E}\big[C^{\mathrm{pert}}_{\mathrm{máx}}\big] - C^{\mathrm{nom}}_{\mathrm{máx}}}{C^{\mathrm{nom}}_{\mathrm{máx}}}. \tag{1}$$

Variantes de (1) aparecen a lo largo de la literatura de programación robusta (Leon, Wu and Storer, 1994; Mehta and Uzsoy, 1998; Goren and Sabuncuoglu, 2008; Sabuncuoglu and Bayiz, 2000) y se han trasladado a la literatura de programación con DRL en buena medida sin examen (Smit, Zhou and Bekker, 2025; Huang, Ye and Yang, 2025; Xu, Mei, Zhang and Zhang, 2025). El índice tiene una lectura atractiva: es adimensional, es comparable entre instancias de distinto tamaño y un valor cercano a cero dice que la perturbación le costó poco al método.

Este trabajo sostiene que (1) no puede soportar el peso comparativo que se le impone, y que el problema es estructural antes que una cuestión de ruido de estimación. El denominador es el makespan nominal del propio método. Un método que produce una planificación nominal deficiente queda así calificado contra una referencia indulgente, y uno que produce una planificación casi óptima, contra una exigente. La Sección 4 lo hace exacto: con r la desviación relativa del makespan nominal respecto de un óptimo certificado y q la desviación relativa del makespan realizado respecto del mismo óptimo, $\mathrm{RI} = (q - r)/(1 + r)$, cuya derivada parcial en r es estrictamente negativa. Dos métodos que entregan planificaciones ejecutadas *idénticas* quedan ordenados por RI en orden inverso a la calidad de los planes de los que partieron.

La consecuencia no es hipotética. Reanalizamos un corpus preregistrado de 4,500 ejecuciones perturbadas que cubre tres clases de perturbación a tres severidades cada una — averías de máquina, tiempos de proceso estocásticos y llegadas dinámicas de trabajos — para nueve reglas de despacho por prioridad y una política GNN–PPO heterogénea, junto con 43 instancias nominales con óptimos probados. En cada uno de los 9 regímenes, RI correlaciona por rangos de forma negativa con cuán mala fue la planificación nominal — de manera casi perfecta en los 6 regímenes que comparan diez métodos — y el método que nomina como más robusto nunca es el que efectivamente termina más cerca del óptimo. Bajo averías y tiempos estocásticos el índice corona a la regla de razón crítica, cuyas planificaciones nominales se sitúan un 220 % por encima del óptimo; bajo llegadas dinámicas corona a menor trabajo restante, con 187 %. Ambas están entre los peores desempeños una vez que la planificación ejecutada se mide contra una referencia fija.

Contribuciones. Este trabajo hace cuatro.

(I) **Una caracterización analítica del modo de falla.** La Proposición 1 descompone RI en desviación nominal y realizada y muestra la dependencia monótona de la primera; el Corolario 2 identifica el RI negativo — reportado rutinariamente como robustez elevada — como la firma de una planificación nominal tan deficiente que la perturbación la mejora en esperanza.

(II) **Una cuantificación del error de decisión resultante.** En los 9 regímenes, el orden por RI y el orden por calidad realizada discrepan sin excepción, y actuar según el primero cuesta 15.8–49.3 puntos porcentuales de desviación respecto del óptimo.

(III) **Un protocolo de medición corregido.** La calidad realizada frente a un óptimo certificado, reportada junto con una cola CVaR_{90} y contra tres comparadores de despacho explícitamente separados, restablece la comparabilidad entre métodos. El protocolo no exige experimentos adicionales: es una remedición de ejecuciones ya realizadas.

(IV) **Una reevaluación de la política aprendida bajo ese protocolo.** La política GNN–PPO no es significativamente peor que el comparador mejor clasificado en ninguno de los 9 regímenes según la diferencia crítica de Nemenyi y ocupa el primer lugar en 5, incluidos los tres de llegadas dinámicas, mientras que el índice convencional la sitúa cerca del fondo. A lo largo del trabajo leemos un no rechazo como un empate y no como una victoria.

La Sección 2 sitúa el argumento. La Sección 3 fija el problema y el modelo de perturbación. La Sección 4 desarrolla el marco de medición. La Sección 5 describe el diseño experimental y el preregistro que lo gobierna. La Sección 6 reporta la auditoría. La Sección 7 discute implicaciones y limitaciones, y la Sección 8 concluye.

2. Trabajo relacionado

2.1. Aprender a programar

Las reglas de despacho siguen siendo el estándar operativo en talleres dinámicos porque son baratas, interpretables y no exigen más estado del que la planta ya registra (Haupt, 1989; Holthaus and Rajendran, 1997). Su debilidad es que ninguna regla domina: el desempeño depende de la carga del taller, de la holgura de las fechas de entrega y del régimen de perturbación. Aprender una política de despacho es un intento de obtener el carácter en línea de una regla con la adaptabilidad a la instancia de la búsqueda. Zhang et al. (2020) plantearon la programación de talleres como toma de decisiones secuencial sobre un grafo disyuntivo y aprendieron una política con optimización de política proximal (Schulman, Wolski, Dhariwal, Radford and Klimov, 2017); Park et al. (2021) y Song et al. (2023) extendieron la idea a codificaciones de grafo más ricas y a la variante flexible. Las revisiones recientes (Kayhan and Yildiz, 2023; Smit et al., 2025; Huang et al., 2025; Xu et al., 2025) documentan un crecimiento rápido del área y, de manera notable, coinciden en observar que la práctica de evaluación es lo bastante heterogénea como para dificultar la comparación entre trabajos.

2.2. Medición de la robustez en programación

La programación robusta distingue la *robustez* — la calidad de solución retenida bajo realización — de la *estabilidad*, el grado en que la planificación ejecutada se parece a la planeada (Leon et al., 1994; Goren and Sabuncuoglu, 2008). Ambas se miden habitualmente respecto del plan del propio método. Leon et al. (1994) definen la robustez a través del incremento esperado de makespan relativo a la planificación determinista; Mehta and Uzsoy (1998) miden la predictibilidad de forma análoga; Sabuncuoglu and Bayiz (2000) y Aytug et al. (2005) revisan las variantes reactivas de la misma construcción. Herroelen and Leus (2005) señalan, en el contexto de la programación de proyectos, que tales medidas confunden la calidad de la línea base con su resiliencia, pero la observación no ha permeado la práctica de evaluación en programación de máquinas y, en particular, no ha llegado a la literatura de DRL, donde el índice suele heredarse sin examinar qué hace su denominador.

Nuestra contribución aquí es precisar esa confusión y mostrar que no es una preocupación de segundo orden: en los regímenes que estudiamos es el término dominante e invierte el orden inducido.

2.3. Higiene de evaluación en métodos aprendidos

La literatura de reproducibilidad en aprendizaje por refuerzo ha encontrado repetidamente que las ganancias reportadas son sensibles a las semillas, a la elección de línea base y al procedimiento estadístico (Henderson, Islam, Bachman, Pineau, Precup and Meger, 2018; Agarwal, Schwarzer, Castro, Courville and Bellemare, 2021). Los remedios que allí se proponen — preregistro de hipótesis, definiciones explícitas de comparador, pruebas libres de distribución sobre conjuntos de instancias y reporte de colas antes que solo de medias (Demšar, 2006; García and Herrera, 2008; Munafò, Nosek, Bishop, Button, Chambers, Percie du Sert, Simonsohn, Wagenmakers, Ware and Ioannidis, 2017; Kerr, 1998) — se trasladan directamente a la programación, donde el conjunto de instancias hace las veces de distribución de tareas. Este trabajo los aplica y añade un requisito específico del dominio: la referencia contra la que se mide la calidad debe ser externa al método que se califica.

3. Planteamiento del problema

3.1. El problema flexible dinámico de taller

Una instancia comprende un conjunto de trabajos $\mathcal{J} = \{J_1, \dots, J_n\}$ y máquinas $\mathcal{M} = \{M_1, \dots, M_m\}$. El trabajo J_i es una cadena de operaciones $O_{i1} \prec O_{i2} \prec \cdots \prec O_{in_i}$; la operación O_{ij} puede procesarse en cualquier máquina de un conjunto de elegibilidad $\mathcal{M}_{ij} \subseteq \mathcal{M}$, tomando p_{ijk} unidades de tiempo en $M_k \in \mathcal{M}_{ij}$. En el taller clásico $|\mathcal{M}_{ij}| = 1$ para todo (i, j). Las máquinas procesan una operación a la vez y las operaciones no son interrumpibles una vez iniciadas. Una solución asigna a cada operación una máquina y un instante de inicio consistentes con la precedencia y la capacidad; el objetivo es el makespan $C_{\max} = \max_i C_{in_i}$.

La variante dinámica permite que la instancia cambie durante la ejecución. Escribimos ξ para una realización del proceso de perturbación y $C^{\text{pert}}_{\max}(\xi)$ para el makespan efectivamente alcanzado cuando las decisiones de un método se ejecutan contra ξ.

3.2. Clases de perturbación

Se modelan tres clases de perturbación, cada una a tres severidades, dando los 9 regímenes de la malla experimental. Las parametrizaciones se fijaron antes de observar cualquier resultado (Sección 5.5).

Averías de máquina. Cada máquina alterna entre estados disponible y en reparación, calibrados a una disponibilidad objetivo $A_k \in \{0{,}95;\ 0{,}90;\ 0{,}80\}$. Los tiempos hasta falla son exponenciales y los tiempos de reparación log-normales con forma $\sigma_{\mathrm{TTR}} = 0{,}5$ y un multiplicador de tiempo medio de reparación de 2,0. Una operación en curso cuando falla su máquina se reanuda al reparar.

Tiempos de proceso estocásticos. Las duraciones realizadas se sortean como $\tilde{p}_{ijk} = p_{ijk} \cdot \varepsilon$ con $\varepsilon \sim$ LogNormal calibrada a media unitaria y coeficiente de variación $\sigma \in \{0{,}10;\ 0{,}25;\ 0{,}50\}$, de modo que la instancia esperada no cambia y solo varía su dispersión.

Llegadas dinámicas de trabajos. Los nuevos trabajos llegan según un proceso de Poisson cuya tasa se calibra a una utilización de máquina objetivo $\rho \in \{0{,}70;\ 0{,}85;\ 0{,}95\}$, hasta un horizonte tras el cual no ocurren más llegadas.

3.3. Semántica de ejecución

La distinción entre métodos que deciden una vez y métodos que deciden de forma continua debe hacerse explícita, porque determina qué significa siquiera un makespan perturbado.

Un método *fuera de línea* (programación con restricciones, algoritmo genético) produce una planificación completa contra la instancia nominal. Bajo perturbación esa planificación se ejecuta con reparación por desplazamiento a la derecha: se conserva la secuencia de máquina y los instantes de inicio se empujan hacia adelante según sea necesario para respetar las duraciones, disponibilidades y fechas de liberación realizadas. Un método *en línea* (una regla de despacho, una política aprendida) se invoca en cada punto de decisión contra el estado tal como está y, por tanto, nunca sostiene una secuencia que deba reparar.

Esta asimetría es intrínseca a la comparación y no intentamos eliminarla. Sí nos negamos, en cambio, a dejar que se esconda dentro de una métrica: el marco de la Sección 4 califica a ambas familias contra la misma referencia externa.

No toda regla de despacho sobrevive a los regímenes de llegadas. 5 de las nueve quedan excluidas allí, por dos razones distintas. EDD y CR requieren fechas de entrega, y las de trabajos que no existían cuando se creó la instancia no están definidas por ella; sintetizarlas en línea es una decisión de modelado, no un detalle de implementación. SPT, LPT y MWKR requieren magnitudes de duración o trabajo restante por operación indexadas contra el conjunto original de operaciones, que la implementación no mantiene para trabajos que llegan de forma dinámica. Cuatro reglas (FIFO, MOR, LOR, LWKR) más la política aprendida se comparan por tanto bajo llegadas, frente a diez métodos en el resto.

Esta restricción importa para cómo deben leerse los resultados de llegadas, y la señalamos aquí antes que en una nota al pie: MWKR, que supera en rango a la política aprendida en cinco de los seis regímenes restantes, está entre las reglas excluidas. La comparación bajo llegadas se hace por tanto contra un campo más débil que las de averías y tiempos estocásticos, y el primer lugar de la política allí es un primer lugar entre cuatro reglas, no entre nueve. La Sección 7.4 vuelve sobre esto. Levantar la restricción exige rastrear el instante real de llegada de cada trabajo y recomputar el estado de las reglas contra un conjunto de operaciones creciente — un cambio de representación de estado que no intentamos, y que declaramos en lugar de resolver.

4. Un marco de medición

4.1. El índice convencional y lo que hace su denominador

Definición 1 (Índice de robustez). Para un método que produce makespan nominal $C^{\mathrm{nom}}_{\mathrm{máx}}$ y makespan perturbado esperado $\mathbb{E}[C^{\mathrm{pert}}_{\mathrm{máx}}]$ en la misma instancia,

$$\mathrm{RI} = \frac{\mathbb{E}[C^{\mathrm{pert}}_{\mathrm{máx}}] - C^{\mathrm{nom}}_{\mathrm{máx}}}{C^{\mathrm{nom}}_{\mathrm{máx}}}.$$

Sea $C^{\star}_{\text{máx}}$ un óptimo certificado de la instancia nominal y defínanse las dos desviaciones *referenciadas externamente*

$$r = \frac{C^{\text{nom}}_{\text{máx}} - C^{\star}_{\text{máx}}}{C^{\star}_{\text{máx}}}, \qquad q = \frac{\mathbb{E}[C^{\text{pert}}_{\text{máx}}] - C^{\star}_{\text{máx}}}{C^{\star}_{\text{máx}}}. \tag{2}$$

Aquí r es la conocida desviación porcentual relativa del plan y q es lo que llamaremos *calidad realizada*: cuán lejos terminó la planificación efectivamente ejecutada respecto de la mejor planificación que existía para la instancia nominal. Ambas se miden contra una referencia que ningún método puede influir.

Proposición 1. *Con r y q como en (2) y $C^{\star}_{\text{máx}} > 0$,*

$$\text{RI} = \frac{q - r}{1 + r}, \qquad y \qquad \left.\frac{\partial \text{RI}}{\partial r}\right|_{q} = -\frac{1+q}{(1+r)^2} < 0. \tag{3}$$

Demostración. Sustituyendo $C^{\text{nom}}_{\text{máx}} = C^{\star}_{\text{máx}}(1+r)$ y $\mathbb{E}[C^{\text{pert}}_{\text{máx}}] = C^{\star}_{\text{máx}}(1+q)$ en la Definición 1 se obtiene $\text{RI} = \big(C^{\star}_{\text{máx}}(1+q) - C^{\star}_{\text{máx}}(1+r)\big)/C^{\star}_{\text{máx}}(1+r) = (q-r)/(1+r)$. Derivando en r con q fijo, $\partial\text{RI}/\partial r = \big[-(1+r) - (q-r)\big]/(1+r)^2 = -(1+q)/(1+r)^2$, negativa siempre que $q > -1$, es decir, siempre que el makespan perturbado sea positivo. □

Corolario 1 (Inversión de orden a igual desempeño)**.** *Dos métodos con idéntica calidad realizada q pero desviaciones nominales $r_1 < r_2$ satisfacen $\text{RI}_1 > \text{RI}_2$. El método con el peor plan recibe la mejor puntuación de robustez.*

Corolario 2 (Índice negativo)**.** $\text{RI} < 0$ *si y solo si $q < r$: el makespan perturbado esperado está* por debajo *del nominal. Esto solo puede ocurrir cuando la planificación nominal era lo bastante deficiente como para que el proceso de perturbación, al reordenar trabajo que aquella había secuenciado mal, la mejore en esperanza.*

El Corolario 2 merece énfasis porque los índices de robustez negativos se reportan en la literatura como evidencia de resiliencia excepcional. Bajo la Definición 1 son, en cambio, un diagnóstico de una línea base mala. Un método no puede beneficiarse de las fallas de máquina; solo puede haber estado programando de forma tan ineficiente que las fallas no eran la restricción activa.

La Proposición 1 es una identidad, no una aproximación. Evaluada sobre las 150 celdas (método × instancia × régimen) de nuestro corpus, la discrepancia absoluta máxima entre RI calculado a partir de makespans crudos y $(q-r)/(1+r)$ calculado a partir de las desviaciones almacenadas es $9{,}4 \times 10^{-6}$; calculada a partir de makespans crudos en ambos lados, la discrepancia cae a ruido de coma flotante, lo que confirma que el residuo es redondeo de las columnas de desviación registradas.

4.2. Calidad realizada

Tomamos q de (2) como la medida primaria de desempeño bajo perturbación y la llamamos calidad realizada, CR. Tiene tres propiedades de las que carece el índice convencional. Está referenciada externamente, de modo que un método no puede mejorar su puntuación planificando mal. Es comparable entre métodos, porque todos los métodos sobre una instancia comparten el denominador $C^{\star}_{\text{máx}}$. Y es comparable con la desviación nominal r en la misma escala, de modo que el costo de la perturbación se lee como la diferencia $q - r$ en lugar de quedar plegado dentro de un cociente.

Tiene también una limitación que conviene declarar. CR mide la planificación ejecutada contra el óptimo *de la instancia nominal*, que bajo llegadas dinámicas no es el óptimo de la instancia efectivamente ejecutada. La cantidad es entonces una desviación referenciada a una cota inferior antes que una brecha de optimalidad verdadera en los regímenes de llegadas; sigue siendo comparable entre métodos, que es lo que la comparación requiere, pero su magnitud absoluta allí no debe leerse como brecha de optimalidad. Por eso reportamos los regímenes de llegadas por separado en todo el trabajo.

4.3. Riesgo de cola

Una media oculta las ejecuciones que un taller efectivamente teme. Reportamos por tanto, junto a $\mathbb{E}[\text{CR}]$, el valor en riesgo condicional al percentil 90,

$$\text{CVaR}_{90}(\text{CR}) = \mathbb{E}\big[\text{CR} \mid \text{CR} \geq \text{VaR}_{90}(\text{CR})\big], \tag{4}$$

la calidad realizada media sobre las realizaciones situadas en el percentil 90 o por encima (Rockafellar and Uryasev, 2000; Artzner, Delbaen, Eber and Heath, 1999). Con 30 semillas por (instancia, método) esto promedia las 3 peores realizaciones, de modo que es una estimación gruesa de la cola y la leemos como una dirección, no como un cuantil preciso. Dos métodos con igual desempeño esperado y distinto comportamiento de cola son operativamente distintos, y un programador elegido para un taller que no puede absorber una terminación tardía debe elegirse por la cola.

4.4. Disciplina de comparadores

Las afirmaciones del tipo «la política supera a la mejor regla de despacho» están indeterminadas hasta que se define *mejor*, y las definiciones disponibles no coinciden. Reportamos las tres, siempre por separado y siempre etiquetadas.

$\mathrm{PDR}_{\mathrm{global}}$ la desviación media sobre las nueve reglas: lo que obtiene un profesional que no ha afinado la selección de regla.

$\mathrm{PDR}_{\mathrm{family}}$ la media, sobre las cinco familias de comportamiento (basadas en duración, trabajo restante, operaciones restantes, llegada y fecha de entrega), de la mejor regla *dentro* de esa familia en esa instancia. Es una construcción intermedia: más fuerte que cualquier regla desplegable individual, porque la elección dentro de la familia se hace por instancia, pero más débil que el oráculo de abajo, porque no puede cruzar fronteras de familia.

$\mathrm{PDR}_{\mathrm{oracle}}$ la desviación mínima por instancia: alcanzable solo conociendo la respuesta y, por tanto, una cota superior al desempeño de las reglas antes que una línea base desplegable.

La Sección 6.5 muestra que estos tres arrojan veredictos opuestos sobre los mismos datos, que es precisamente la razón por la que un trabajo que reporta uno sin nombrarlo no ha reportado un resultado.

5. Diseño experimental

5.1. Instancias y valores de referencia

El corpus nominal son las 43 instancias estándar de taller incluidas en la OR-Library — `ft06`, `ft10`, `ft20` (Fisher and Thompson, 1963) y `la01`–`la40` (Lawrence, 1984). Toda instancia de este conjunto tiene óptimo probado, verificado como tal en la tabla de referencia adjunta, de modo que la desviación r es una brecha de optimalidad verdadera y no una aproximación a una cota conocida. La malla de perturbación usa `ft06` (6×6) y `la01` (10×5), el par contra el que se validó la maquinaria de perturbación.

5.2. Métodos

Nueve reglas de despacho por prioridad abarcan cinco familias de comportamiento: tiempo de proceso más corto y más largo (SPT, LPT); mayor y menor trabajo restante (MWKR, LWKR); mayor y menor número de operaciones restantes (MOR, LOR); primero en entrar primero en salir (FIFO); y fecha de entrega más próxima y razón crítica (EDD, CR). Un modelo de programación con restricciones resuelto con CP-SAT (Perron and Furnon, 2024) aporta la referencia exacta y un algoritmo genético generacional la referencia metaheurística. El método aprendido es un codificador de red neuronal de grafos heterogénea de la familia GIN (Xu, Hu, Leskovec and Jegelka, 2019) sobre un grafo con tipos de arista distintos para precedencia, compartición de máquina y elegibilidad, entrenado con PPO enmascarable (Schulman et al., 2017; Raffin, Hill, Gleave, Kanervisto, Ernestus and Dormann, 2021) bajo un currículo con aleatorización de dominio (Tobin, Fong, Ray, Schneider, Zaremba and Abbeel, 2017). Los hiperparámetros se fijaron mediante una búsqueda con Optuna (Akiba, Sano, Yanase, Ohta and Koyama, 2019) realizada antes de la campaña confirmatoria y reportada por separado; la campaña aquí analizada emplea sin cambios la configuración resultante.

5.3. Malla y replicación

Cada uno de los 9 regímenes de la Sección 3.2 se ejecuta con 30 semillas de perturbación independientes sobre cada una de las dos instancias, dando 30×2 bloques pareados por régimen y 4,500 ejecuciones perturbadas en total. Se comparan diez métodos en los seis regímenes de averías y tiempos estocásticos, y cinco en los tres regímenes de llegadas, por la razón dada en la Sección 3.3.

Cuadro 1
Correlación de rangos entre la desviación nominal y el índice de robustez convencional, por régimen. k es el número de métodos comparados. Un ρ_s fuertemente negativo significa que los métodos con peores planificaciones nominales reciben mejores puntuaciones de robustez.

Clase de perturbación	Severidad	k	ρ_s	p
Averías	$A_k = 0{,}95$	10	$-0{,}985$	$2{,}3 \times 10^{-7}$
	$A_k = 0{,}90$	10	$-0{,}948$	$2{,}9 \times 10^{-5}$
	$A_k = 0{,}80$	10	$-0{,}948$	$2{,}9 \times 10^{-5}$
Tiempos estocásticos	$\sigma = 0{,}10$	10	$-0{,}948$	$2{,}9 \times 10^{-5}$
	$\sigma = 0{,}25$	10	$-0{,}985$	$2{,}3 \times 10^{-7}$
	$\sigma = 0{,}50$	10	$-0{,}948$	$2{,}9 \times 10^{-5}$
Llegadas dinámicas	$\rho = 0{,}70$	5	$-0{,}800$	0.104
	$\rho = 0{,}85$	5	$-0{,}800$	0.104
	$\rho = 0{,}95$	5	$-0{,}800$	0.104

Convención de referencia nominal. Exactamente una corrida determinista por (instancia, método) entra en la referencia nominal. Cada línea base aporta su única planificación determinista; la política aprendida aporta su despliegue determinista, y los cuatro despliegues estocásticos adicionales que se registraron para ella se reportan de forma descriptiva y nunca entran en una prueba, conforme al preregistro. Así la unidad de análisis es idéntica entre métodos.

5.4. Protocolo estadístico

Dentro de un régimen, los métodos se comparan mediante una prueba de Friedman sobre bloques definidos por (instancia, semilla), seguida — en caso de rechazo — de un post-hoc de Nemenyi con diferencia crítica $\mathrm{CD} = q_\alpha \sqrt{k(k+1)/6N}$ para k métodos y N bloques (Demšar, 2006; García and Herrera, 2008). Las comparaciones pareadas de dos métodos usan la prueba de rangos con signo de Wilcoxon con la correlación biserial de rangos como tamaño de efecto. La asociación entre métricas usa ρ_s de Spearman y, para el acuerdo de ordenamiento, τ de Kendall. Todas las pruebas son bilaterales con $\alpha = 0{,}05$. Dado que la auditoría reporta una prueba de Friedman por régimen y que estos regímenes están preregistrados como familias confirmatorias separadas y no como una hipótesis agrupada, no se aplica corrección por multiplicidad entre regímenes; los valores p por régimen se reportan completos para que el lector pueda aplicar la corrección que prefiera.

5.5. Preregistro y reproducibilidad

Las hipótesis, el conjunto de instancias, la malla de perturbación, las pruebas estadísticas y las reglas de aceptación y rechazo se congelaron en un documento de preregistro fechado antes de entrenar cualquier política y de ejecutar cualquier corrida perturbada, siguiendo las recomendaciones de Munafò et al. (2017) y la preocupación específica sobre formación posterior de hipótesis planteada por Kerr (1998). El análisis que aquí se reporta es una *remedición* del corpus preregistrado: no se añadió, eliminó ni reejecutó ninguna corrida, y los registros crudos por corrida están inalterados. La remedición es en sí misma posterior respecto de esa congelación — la motivó una auditoría de la métrica, no quedó registrada de antemano — y se etiqueta como tal en todo el trabajo. Lo que no hace es alterar dato alguno sobre el que se computaron los veredictos originales.

El Apéndice A expone el programa de investigación del que surge el corpus.

6. Resultados

6.1. El índice de robustez queda determinado por la calidad nominal

La Tabla 1 reporta, para cada régimen, la correlación de rangos de Spearman entre la desviación nominal de un método y su índice de robustez.

La correlación es negativa en los 9 regímenes. En los 6 de averías y tiempos estocásticos, donde se comparan diez métodos, ρ_s va de $-0{,}985$ a $-0{,}948$ (mediana $-0{,}948$) con $p \leq 3 \times 10^{-5}$: un ordenamiento casi determinista. Los 3 regímenes de llegadas dan $\rho_s = -0{,}800$ en los tres, pero con solo cinco métodos una

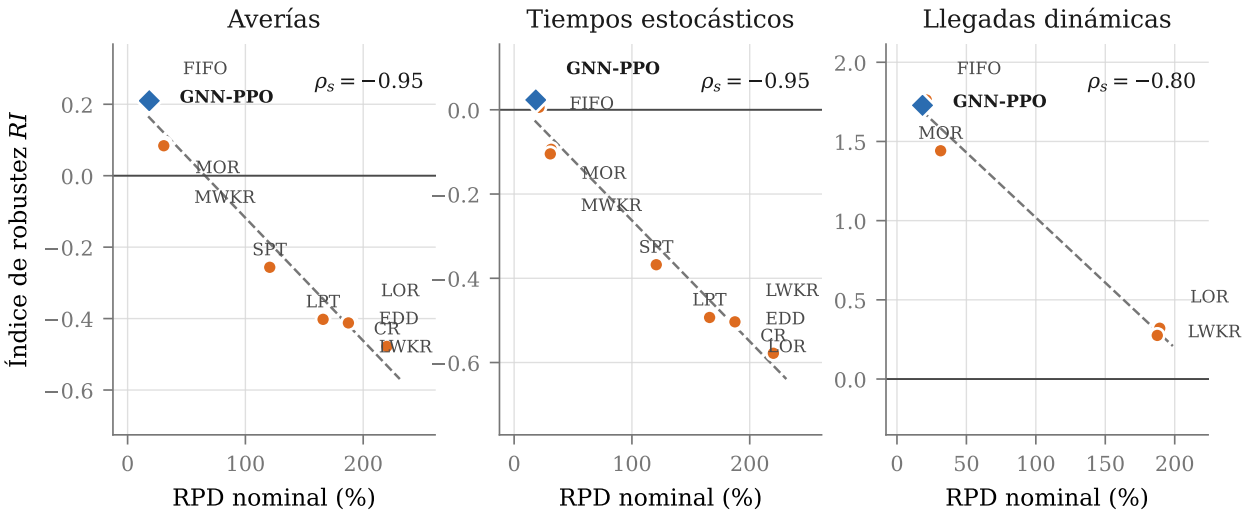


Figura 1: El índice de robustez frente a la desviación nominal, agregado por clase de perturbación. Cada punto es un método. La línea discontinua es un ajuste por mínimos cuadrados mostrado solo como orientación; el estadístico reportado es la correlación de rangos. Los métodos cuyas planificaciones nominales quedan más lejos del óptimo (CR, LWKR, LOR, EDD) obtienen los índices más negativos — es decir, convencionalmente, los más robustos.

prueba de Spearman sobre $k = 5$ puntos tiene poca potencia y los reportamos de forma descriptiva antes que como confirmación. La Figura 1 muestra la relación subyacente: el índice es, con buena aproximación, una función afín decreciente de la desviación nominal, exactamente como predice la Proposición 1.

97 de las 150 celdas (método × instancia × régimen) del corpus — el 65 % — tienen RI < 0. Por el Corolario 2 cada una es un caso en que el makespan perturbado esperado está por debajo del nominal, y verificamos que la equivalencia se cumple exactamente: en el 100 % de las celdas, signo(RI) coincide con signo$(q - r)$. La regla de razón crítica sobre `ft06` con $A_k = 0{,}90$ es representativa: su makespan nominal de 171 cae a una media de 94,1 bajo averías. La regla calcula una razón de criticidad a partir de fechas de entrega sintetizadas una sola vez contra duraciones nominales y jamás recalculadas conforme avanza el reloj realizado, de modo que bajo perturbación sus decisiones de ordenamiento se vuelven progresivamente menos relacionadas con el estado que ordenan; el reordenamiento casi aleatorio resultante mejora una secuencia que estaba mal elegida desde el principio. Esto es regresión a la media, y el índice lo registra como resiliencia.

6.2. Inversión de orden y el costo de actuar según ella

Si el índice se limitara a añadir ruido, seguiría siendo utilizable en esperanza. No lo hace: induce un ordenamiento sistemáticamente opuesto al orden por calidad realizada.

El τ de Kendall es negativo en los 9 regímenes (Tabla 2, rango $-0{,}60$ a $-0{,}29$), y los dos criterios nunca eligen el mismo método. Las pruebas individuales de τ por régimen resultan significativas solo en una minoría — con diez métodos como máximo por régimen tienen poca potencia —, pero el signo es negativo sin excepción, y es la consistencia de ese signo a lo largo de nueve regímenes independientes, y no ningún valor p aislado, lo que sostiene la afirmación. El índice elige la regla de razón crítica en los 6 regímenes de averías y tiempos estocásticos, y menor trabajo restante en los 3 de llegadas. La calidad realizada elige mayor trabajo restante o la política aprendida. La penalización por seguir al índice — la diferencia en calidad realizada entre el método que nomina y el que realmente es mejor — va de 15.8 a 49.3 puntos porcentuales, con mediana 25.7. La Figura 2 muestra la inversión de forma directa.

6.3. Calidad realizada y riesgo de cola

La Tabla 3 da el panel completo de métricas. Leer las columnas unas contra otras es instructivo: el orden de la columna RI se aproxima al inverso del orden de la columna CR, y la columna de desviación nominal explica el primero casi por completo.

Cuadro 2
Desacuerdo entre los dos ordenamientos. τ es la correlación de rangos de Kendall entre el orden por RI y el orden por calidad realizada. Las tres últimas columnas dan la calidad realizada del método que nomina el índice, la del método realmente mejor, y la penalización de seguir al índice.

Clase	Severidad	τ	Método elegido		Calidad realizada (%)		
			por RI	por CR	del 1.º	del 2.º	penaliz.
Averías	$A_k = 0{,}95$	$-0{,}600$	CR	MWKR	46.9	23.6	+23,3
	$A_k = 0{,}90$	$-0{,}422$	CR	MWKR	63.3	34.8	+28,5
	$A_k = 0{,}80$	$-0{,}511$	CR	**GNN–PPO**	90.6	64.9	+25,7
Tiempos estocásticos	$\sigma = 0{,}10$	$-0{,}289$	CR	MWKR	30.6	12.3	+18,4
	$\sigma = 0{,}25$	$-0{,}378$	CR	MWKR	33.7	13.7	+20,0
	$\sigma = 0{,}50$	$-0{,}511$	CR	MWKR	40.8	24.9	+15,8
Llegadas dinámicas	$\rho = 0{,}70$	$-0{,}400$	LWKR	**GNN–PPO**	268.0	230.4	+37,6
	$\rho = 0{,}85$	$-0{,}600$	LWKR	**GNN–PPO**	268.1	219.2	+48,9
	$\rho = 0{,}95$	$-0{,}400$	LWKR	**GNN–PPO**	261.1	211.7	+49,3

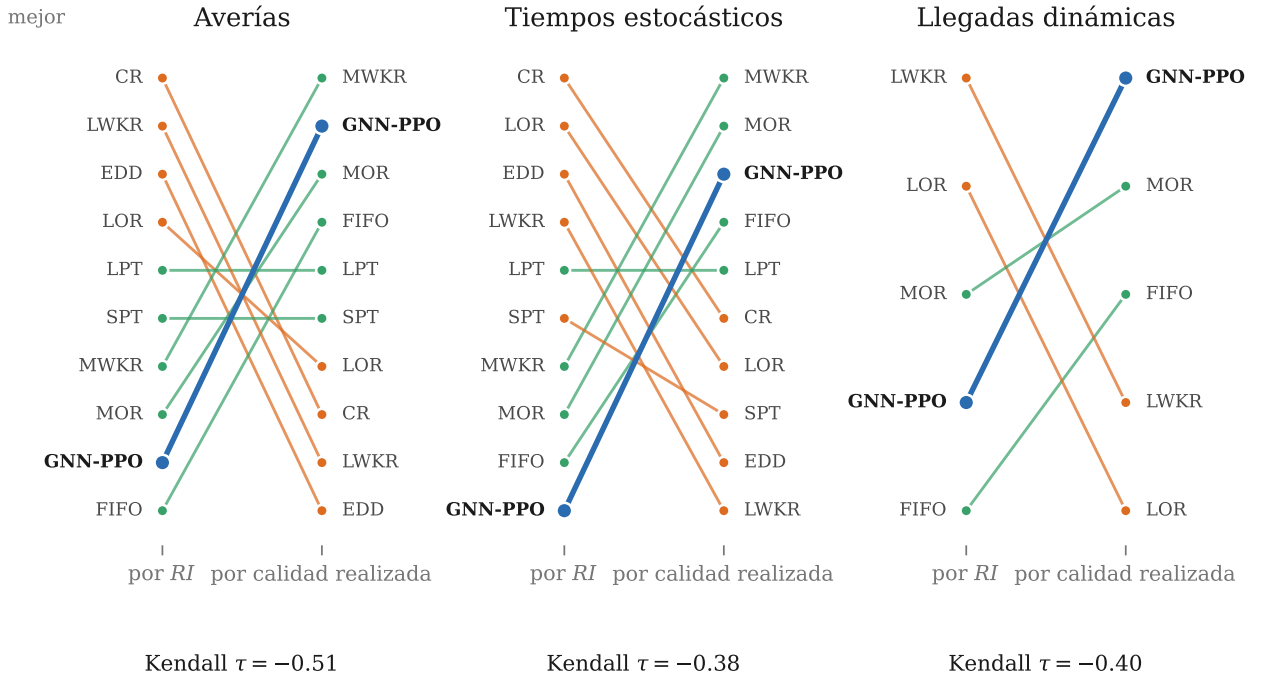


Figura 2: Ordenamiento por el índice de robustez (izquierda) frente al ordenamiento por calidad realizada (derecha), por clase de perturbación. Las líneas que descienden de izquierda a derecha corresponden a métodos que el índice favorece indebidamente. La política aprendida viaja de casi la peor posición a la mejor; las reglas de fecha de entrega viajan en sentido contrario.

Bajo averías la política aprendida alcanza CR = 41,8 % con CVaR_{90} = 85,3 % — la mejor cola del panel — mientras que MWKR alcanza una media marginalmente mejor (41,7 %) con peor cola (88,0 %). La regla de razón crítica, que el índice convencional sitúa primera, realiza 67,0 % con una cola de 131,1 %. Bajo tiempos de proceso estocásticos MWKR lidera en media y en cola, con la política en tercer lugar. Bajo llegadas dinámicas la política lidera en media y MOR en cola, ambas próximas; las magnitudes absolutas en esta clase son grandes por la razón dada en la Sección 4 y deben leerse comparativamente. La Figura 3 muestra media y cola conjuntamente.

Cuadro 3
Panel de métricas por clase de perturbación, métodos ordenados por calidad realizada. r es la desviación nominal respecto del óptimo certificado; RI el índice convencional; CR la calidad realizada; CVaR_{90} la media de su peor decil. Todos en porcentaje. * marca la política aprendida.

Método	r (%)	RI	CR (%)	CVaR_{90} (%)
Averías				
MWKR	30.7	+0.084	41.7	88.0
GNN–PPO*	18.4	+0.210	41.8	85.3
MOR	31.5	+0.090	43.2	85.6
FIFO	21.1	+0.212	46.8	89.6
LPT	165.9	-0.402	57.7	107.4
SPT	120.7	-0.256	64.2	122.8
LOR	189.2	-0.410	65.8	130.3
CR	220.1	-0.478	67.0	131.1
LWKR	187.4	-0.412	68.8	134.6
EDD	187.4	-0.411	69.2	129.7
Tiempos estocásticos				
MWKR	30.7	-0.105	17.0	36.0
MOR	31.5	-0.094	19.1	38.0
GNN–PPO*	18.4	+0.023	20.0	43.4
FIFO	21.1	+0.006	21.9	49.4
LPT	165.9	-0.493	33.2	59.8
CR	220.1	-0.578	35.0	67.0
LOR	189.2	-0.505	38.6	69.8
SPT	120.7	-0.368	39.6	63.8
EDD	187.4	-0.505	42.2	71.4
LWKR	187.4	-0.503	42.6	74.6
Llegadas dinámicas				
GNN–PPO*	18.4	+1.728	220.4	275.1
MOR	31.5	+1.441	221.1	273.4
FIFO	21.1	+1.762	234.7	287.1
LWKR	187.4	+0.275	265.7	307.6
LOR	189.2	+0.321	266.4	310.6

6.4. Separación de métodos bajo la métrica corregida

La hipótesis nula de Friedman se rechaza en todos los regímenes con $p \leq 6{,}7 \times 10^{-28}$ (Tabla 4), de modo que los métodos son distinguibles en calidad realizada en todas partes. La política aprendida es el método mejor clasificado en 5 de 9 regímenes y no es significativamente peor que el mejor clasificado en ninguno de los 9.

Bajo llegadas dinámicas la política ocupa el primer rango en los tres regímenes, con rangos promedio de 1.57–1.62 frente a una diferencia crítica de 0.79. No queda, sin embargo, separada de todo el campo: MOR la sigue por apenas 0.11–0.20 puntos de rango, holgadamente dentro de la diferencia crítica, de modo que el enunciado correcto es que la política y MOR empatan estadísticamente en la cima mientras FIFO, LWKR y LOR quedan fuera. La Figura 4 muestra los diagramas de diferencia crítica, en los que la barra de camarilla abarca exactamente ese par. La misma lectura aplica en los otros seis regímenes, donde la camarilla de la política contiene además a MWKR, MOR y FIFO: en ningún punto de este corpus la política aprendida se separa de todas las reglas.

6.5. Sensibilidad al comparador

La Tabla 5 evalúa los tres comparadores de la Sección 4.4 sobre el corpus nominal de 43 instancias.

El veredicto sobre la política aprendida depende por completo del comparador elegido. Frente a la media de las nueve reglas gana por 233.4 puntos porcentuales; frente a la mejor regla por familia, por 132.4; frente al

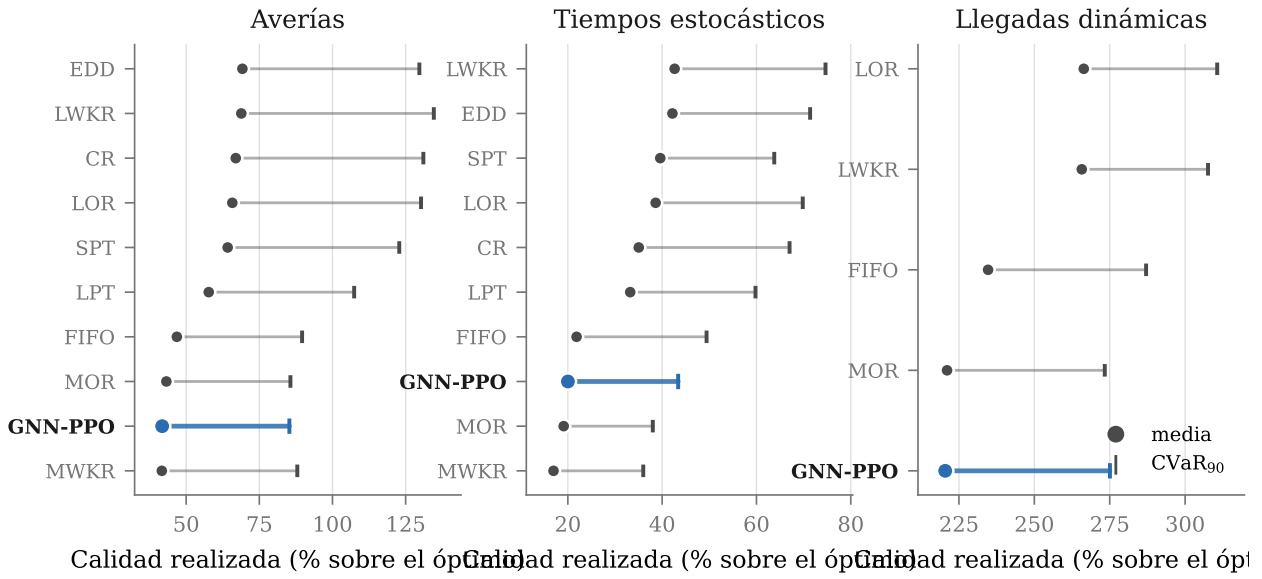


Figura 3: Calidad realizada por método y clase de perturbación. El círculo es la media, la marca vertical el CVaR_{90}, y el segmento entre ambos la exposición de cola. Los métodos están ordenados por calidad realizada media.

Cuadro 4
Pruebas de Friedman sobre calidad realizada con post-hoc de Nemenyi, por régimen. Los bloques son pares (instancia, semilla). La última columna indica si la política aprendida es estadísticamente indistinguible del método mejor clasificado a la diferencia crítica.

Clase	Severidad	k	N	χ^2	p	CD	Mejor rango	Rango GNN–PPO	Empata
Averías	$A_k = 0{,}95$	10	60	256.0	$< 10^{-8}$	1.75	MWKR	2.83	✓
	$A_k = 0{,}90$	10	60	252.5	$< 10^{-8}$	1.75	**GNN–PPO**	2.83	✓
	$A_k = 0{,}80$	10	60	170.4	$< 10^{-8}$	1.75	**GNN–PPO**	3.12	✓
Tiempos estocásticos	$\sigma = 0{,}10$	10	60	289.1	$< 10^{-8}$	1.75	MWKR	3.28	✓
	$\sigma = 0{,}25$	10	60	267.3	$< 10^{-8}$	1.75	MWKR	3.15	✓
	$\sigma = 0{,}50$	10	60	150.6	$< 10^{-8}$	1.75	MWKR	3.85	✓
Llegadas dinámicas	$\rho = 0{,}70$	5	60	183.0	$< 10^{-8}$	0.79	**GNN–PPO**	1.62	✓
	$\rho = 0{,}85$	5	60	200.4	$< 10^{-8}$	0.79	**GNN–PPO**	1.57	✓
	$\rho = 0{,}95$	5	60	190.1	$< 10^{-8}$	0.79	**GNN–PPO**	1.57	✓

oráculo por instancia, *pierde* por 7.6. Las tres diferencias son significativas sobre $N = 43$ instancias pareadas ($p \leq 4{,}1 \times 10^{-5}$; valores exactos en la Tabla 5). Un trabajo que reportara solo la primera afirmaría una victoria decisiva; uno que reportara solo la tercera, una derrota decisiva. Ambos estarían describiendo las mismas corridas. La Figura 5 muestra las tres distribuciones.

6.6. Qué compra la optimalidad bajo perturbación

Una comparación complementaria atañe a la afirmación motivadora de la literatura de programación con DRL. Sobre `ft06` bajo averías con $A_k = 0{,}90$, tanto CP-SAT como el algoritmo genético alcanzan el óptimo probado en lo nominal ($r = 0$). Ejecutados con reparación por desplazamiento a la derecha sobre cinco semillas de perturbación compartidas, realizan 42.0 % y 41.3 % por encima del óptimo respectivamente — frente a 44.1 % de MOR, 46.8 % de MWKR y 48.0 % de la política aprendida. Las diferencias pareadas entre la política y el método exacto o el metaheurístico no son significativas a este tamaño muestral ($p = 0{,}375$ y $p = 0{,}250$; una semilla produce un empate exacto para los tres métodos, dejando $n = 4$ diferencias no nulas). El algoritmo genético consume 30 s por instancia y CP-SAT 0.046 s, frente a 0.095 s del despliegue completo de la política.

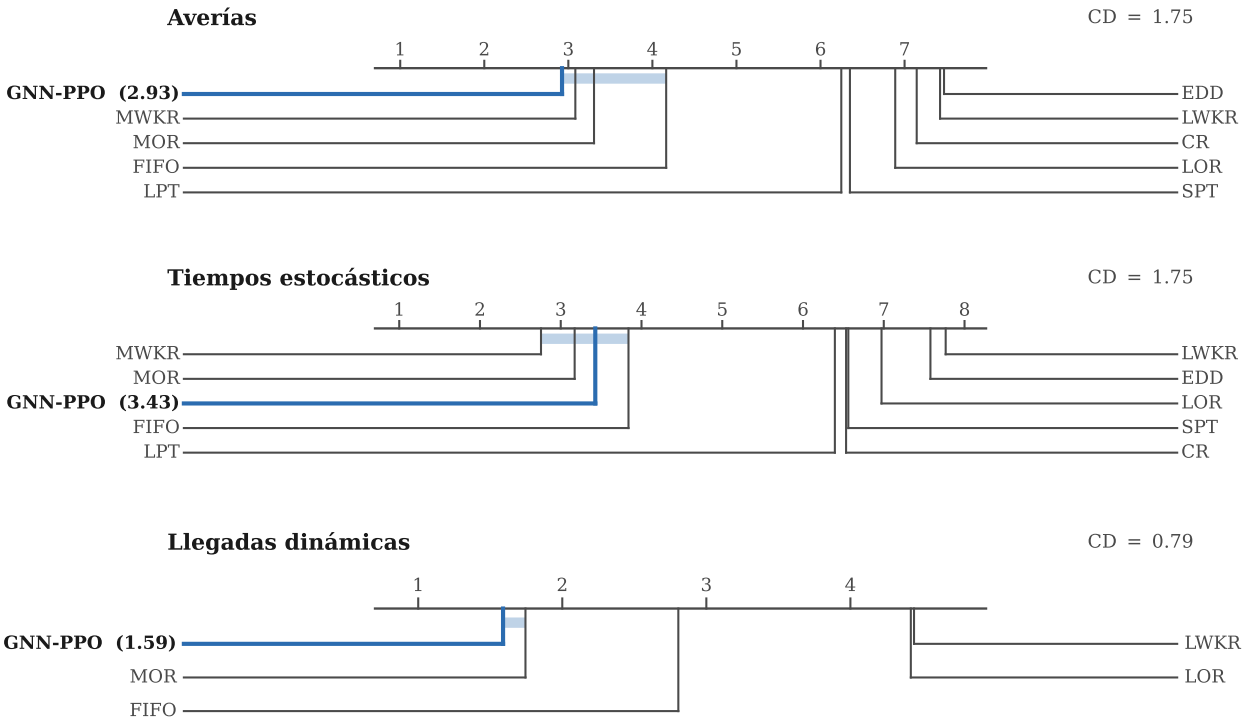


Figura 4: Diagramas de diferencia crítica sobre calidad realizada, uno por clase de perturbación. Los métodos unidos por la barra sombreada no son distinguibles del mejor clasificado con $\alpha = 0{,}05$.

Cuadro 5
La misma política frente a tres definiciones de «mejor regla de despacho». Las desviaciones son RPD respecto del óptimo certificado; la columna de diferencia es la mediana de la diferencia pareada en puntos porcentuales, con z, p de Wilcoxon y tamaño de efecto biserial de rangos sobre las instancias pareadas; $N = 43$ en las filas de la política aprendida y $N = 40$ donde se descartan empates exactos, como registra la columna n.

Comparador	Su RPD	Método	Su RPD	Dif. mediana	n	z	p	r_{rb}	Veredicto
$\mathrm{PDR}_{\mathrm{global}}$	251.4	**GNN–PPO**	24.8	+233,4	43	-5.71	$1{,}1 \times 10^{-8}$	+1,000	GANA
	251.4	GA	5.5	+251,5	43	-5.71	$1{,}1 \times 10^{-8}$	+1,000	GANA
	251.4	CP-SAT	0.0	+254,6	43	-5.71	$1{,}1 \times 10^{-8}$	+1,000	GANA
$\mathrm{PDR}_{\mathrm{family}}$	148.1	**GNN–PPO**	24.8	+132,4	43	-5.71	$1{,}1 \times 10^{-8}$	+1,000	GANA
	148.1	GA	5.5	+144,3	43	-5.71	$1{,}1 \times 10^{-8}$	+1,000	GANA
	148.1	CP-SAT	0.0	+152,1	43	-5.71	$1{,}1 \times 10^{-8}$	+1,000	GANA
$\mathrm{PDR}_{\mathrm{oracle}}$	19.0	**GNN–PPO**	24.8	−7,6	43	-4.11	$4{,}0 \times 10^{-5}$	−0,719	PIERDE
	19.0	GA	5.5	+11,5	40	-5.51	$3{,}6 \times 10^{-8}$	+1,000	GANA
	19.0	CP-SAT	0.0	+21,1	40	-5.51	$3{,}6 \times 10^{-8}$	+1,000	GANA

La lectura que extraemos es deliberadamente cautelosa. Cinco semillas sobre una instancia en un régimen es una observación descriptiva, no una prueba, y así la reportamos. Lo que sí sugiere es que la optimalidad nominal se disipa en buena medida con la ejecución por desplazamiento a la derecha, que es la pregunta sustantiva que el índice de robustez se introdujo para responder y que la calidad realizada responde de forma directa.

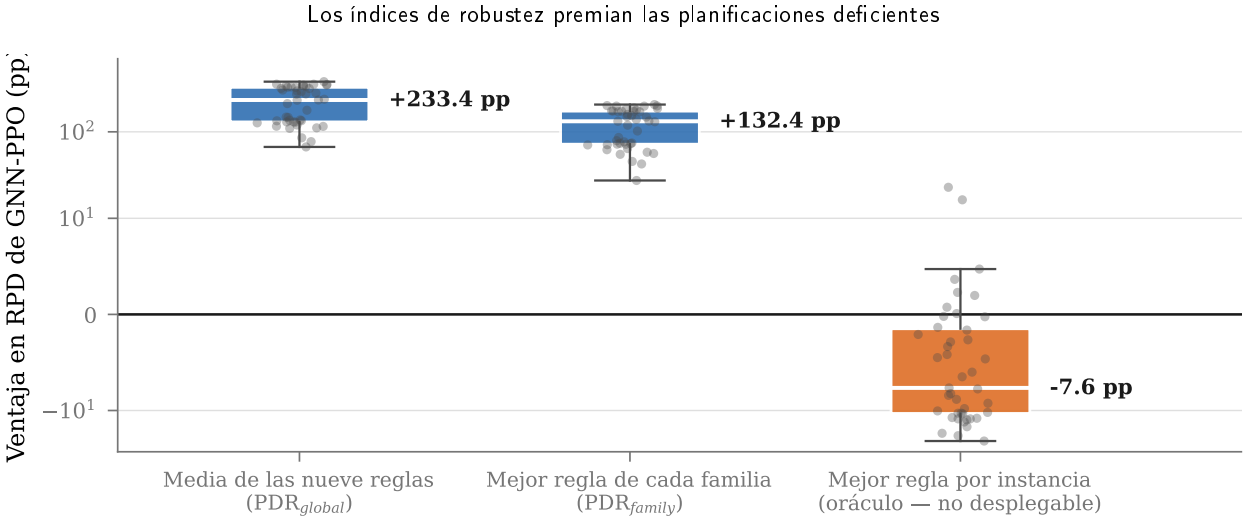


Figura 5: Ventaja de la política aprendida sobre tres definiciones de la línea base de reglas de despacho, por instancia. La escala vertical es logarítmica simétrica. El comparador de oráculo se incluye como calibración y no es desplegable.

7. Discusión

7.1. Qué estaba midiendo el índice

La Proposición 1 muestra que RI es una diferencia normalizada entre calidad realizada y nominal, y la Sección 6.1 muestra que en la práctica domina el término nominal. Conviene entonces entender el índice no como una medida de robustez que resulta ser ruidosa, sino como una medida de una cantidad distinta — a grandes rasgos, cuánto margen se dejó a sí mismo un método — reportada bajo un nombre que invita a la interpretación equivocada. Un método sin margen, porque programó bien, no puede puntuar bien en ella.

Esto no vacía la pregunta subyacente. «¿Cuánto de su calidad planeada retiene un método bajo realización?» es una pregunta real e importante, y la diferencia $q - r$ la responde en una escala interpretable. Lo que debe abandonarse es la normalización por $C^{\text{nom}}_{\text{máx}}$ y, con ella, la práctica de comparar RI entre métodos.

7.2. Implicaciones para los resultados publicados

No estamos en posición de reanalizar los datos de otros autores y no hacemos afirmación alguna sobre la corrección de ningún resultado publicado concreto. Lo que la Proposición 1 sí establece es condicional y, creemos, consecuente: dondequiera que una comparación de métodos descanse sobre un índice de la forma de la Definición 1, y dondequiera que los métodos comparados difieran apreciablemente en calidad nominal, el orden reportado queda confundido por esa diferencia en una dirección conocida y por una magnitud computable. Dado que las políticas aprendidas y las reglas de despacho difieren rutinariamente por un factor de varias unidades en desviación nominal — en las dos instancias de perturbación de este corpus, 18.4 % de la política aprendida frente a 220.1 % de la regla de razón crítica, y 24.8 % frente a 430.3 % sobre el conjunto nominal completo de 43 instancias —, la condición no es un caso límite.

El remedio es barato. La calidad realizada es computable a partir de registros que cualquier estudio de este tipo ya posee, siempre que exista un óptimo certificado o una cota aceptada para la instancia nominal; no exige reejecución. Recomendaríamos reportar r, q y $q - r$ juntos, y reservar el lenguaje de robustez para el tercero.

7.3. Un protocolo de reporte

La auditoría sugiere cuatro requisitos, ninguno gravoso.

(1) Calificar el desempeño perturbado contra una referencia externa al método: un óptimo certificado donde exista y, en su defecto, una cota fija compartida por todos los métodos y nombrada como tal.
(2) Reportar la desviación nominal junto a cualquier cantidad de robustez, de modo que el lector pueda realizar por sí mismo la descomposición de la Proposición 1.
(3) Reportar un estadístico de cola, no solo una media.

(4) Nombrar el comparador. Si la afirmación es contra «la mejor regla de despacho», indicar cuál de las tres construcciones de la Sección 4.4 se entiende, y preferir reportar más de una.

7.4. Amenazas a la validez

Declaramos los límites de este estudio con franqueza, porque varios acotan las conclusiones de forma material.

Amplitud de instancias en la malla de perturbación. Los 9 regímenes se ejecutan sobre dos instancias, `ft06` y `la01`. El resultado analítico de la Proposición 1 es independiente de la instancia, y las correlaciones empíricas se computan entre métodos y no entre instancias, de modo que la afirmación central de la auditoría no descansa sobre la amplitud de instancias. Los hallazgos a nivel de método de la Sección 6.4 sí lo hacen, y deben leerse como válidos para estas dos instancias y este modelo de perturbación, no como un ordenamiento general.

Equivalencia a partir de un no rechazo. Un no rechazo de Nemenyi es una incapacidad de distinguir, no una demostración de equivalencia. Con $k = 10$ y $N = 60$ la diferencia crítica es 1,75 sobre una escala de rangos de 1 a 10, que es amplia; el enunciado de que la política «no es significativamente peor» debe leerse con esa amplitud en mente y no como afirmación de paridad.

Semillas de entrenamiento. La política aprendida es un único punto de control entrenado. Su posición en la Tabla 4 no lleva por tanto estimación alguna de la varianza de entrenamiento, y la literatura de reproducibilidad en aprendizaje por refuerzo es enfática en que esa varianza puede ser grande (Henderson et al., 2018; Agarwal et al., 2021). La infraestructura de entrenamiento multisemilla está implementada y documentada en el repositorio adjunto, pero la campaña multisemilla no había concluido al momento de escribir, y aquí no se afirma ninguna cifra multisemilla.

Cobertura de métodos bajo perturbación. La malla de nueve regímenes compara la política aprendida contra nueve reglas de despacho en seis regímenes y cuatro en los otros tres (Sección 3.3). CP-SAT y el algoritmo genético entran solo por la comparación descriptiva de la Sección 6.6, con una instancia, un régimen y cinco semillas. En consecuencia, dondequiera que este trabajo diga que la política no es significativamente peor que el mejor método, el conjunto de comparación son las reglas de despacho de ese régimen y no los solucionadores exacto y metaheurístico — y en el único régimen donde estos se ejecutaron terminan por delante de la política (42.0 % y 41.3 % frente a 48.0 %), aunque no de forma significativa con $n = 4$. Un brazo completo de métodos fuera de línea a lo largo de la malla es el experimento siguiente natural y convertiría la Sección 6.6 de observación en prueba.

Cobertura de reglas bajo llegadas, y por qué no es conservadora. Cinco de los diez métodos se comparan en los regímenes de llegadas, por las razones dadas en la Sección 3.3. Esto corta en dos direcciones y queremos ser explícitos con ambas. Para la afirmación de medición es casi neutro: el conjunto excluido contiene tanto reglas con planificaciones nominales el conjunto excluido cubre todo el rango: contiene las dos reglas con las peores planificaciones nominales (CR, EDD) y también la de segunda mejor (MWKR, con 30.7 %), de modo que no fabrica la correlación negativa — que en todo caso descansa sobre los 6 regímenes de diez métodos. Para la afirmación sobre la política aprendida es *anti*conservador: MWKR, que supera en rango a la política en cinco de los seis regímenes restantes, queda excluida, de modo que el primer rango de la política bajo llegadas es un primer rango en un campo debilitado. No tratamos por tanto el resultado de llegadas como la evidencia más fuerte a favor de la política, y a un lector que lo descuente por completo le queda el argumento de medición, que no depende de él.

Validez de la referencia bajo llegadas. Como se señaló en la Sección 4, CR bajo llegadas dinámicas está referenciada al óptimo de la instancia nominal y no al de la realizada. Las comparaciones dentro de un régimen siguen siendo válidas; las magnitudes absolutas allí no son brechas de optimalidad.

Carácter posterior de la remedición. La auditoría de medición no fue preregistrada. La motivó un examen de la métrica y se reporta como análisis posterior de un corpus congelado. No se alteró dato alguno, y los

veredictos preregistrados computados sobre la métrica original permanecen tal como quedaron registrados en los materiales adjuntos.

8. Conclusión

El índice de robustez que domina la evaluación de la programación dinámica bajo perturbación normaliza la degradación de un método por su propio makespan nominal. Demostramos que ello lo vuelve estrictamente decreciente en la desviación nominal a desempeño realizado fijo, de modo que cuanto peor es el plan de un método más robusto parece, y que un índice negativo — leído ampliamente como resiliencia excepcional — es la firma de un plan lo bastante deficiente como para que la perturbación lo mejore. En un corpus preregistrado de 4,500 ejecuciones perturbadas en 9 regímenes, el índice correlaciona por rangos de forma negativa con la desviación nominal en todas partes, y con $\rho_s \in [-0{,}985, -0{,}948]$ en los 6 regímenes de campo completo, ordena los métodos de forma opuesta a la calidad realizada en todos los regímenes, y seguirlo cuesta hasta 49.3 puntos porcentuales de desviación respecto del óptimo.

La calidad realizada — la desviación del makespan ejecutado respecto de un óptimo certificado — junto con una cola CVaR_{90} y un comparador de despacho explícitamente nombrado, repara la comparación al costo de una simple remedición. Remedida así, la política GNN–PPO heterogénea no es significativamente peor que la mejor regla de despacho en ninguno de los 9 regímenes y ocupa el primer rango en 5, incluidos los tres de llegadas dinámicas, donde el valor de decidir en línea es mayor — en todos los casos empatada con 1 regla bajo llegadas y 3 en el resto, antes que separada del campo. El índice convencional sitúa a esa misma política cerca del fondo de esas mismas corridas.

El punto más amplio es metodológico. Una métrica cuyo denominador lo elige el método que se califica no puede sostener una comparación entre métodos, y la literatura de programación dispone de una referencia externa bien establecida en los óptimos certificados de sus bancos de prueba estándar. Usarla no cuesta nada y zanja la pregunta que el índice se introdujo para responder.

Declaración de contribución de autoría CRediT

Joseph Javier Sánchez Acuña: Conceptualización, Metodología, Software, Análisis formal, Investigación, Curación de datos, Redacción – borrador original, Redacción – revisión y edición, Visualización.

Declaración de intereses en competencia

El autor declara no tener intereses financieros ni relaciones personales conocidas que pudieran haber influido en el trabajo aquí reportado.

Disponibilidad de datos

El código fuente, el documento de preregistro, los registros crudos por corrida que sustentan cada tabla y figura, y los scripts de análisis que los regeneran están disponibles en el repositorio público adjunto. Cada cifra reportada en la Sección 6, incluida la auditoría de la identidad de la Sección 4 y la comparación de métodos fuera de línea de la Sección 6.6, es producida por esos scripts a partir de esos registros.

A. Programa de investigación

La Figura 6 expone el cronograma del programa de investigación del que surge el corpus, incluido el punto en que se congeló el preregistro y aquel en que se cerró la campaña confirmatoria. La auditoría de medición reportada en este trabajo es posterior a ambos.

CRediT authorship contribution statement

Joseph Javier Sánchez Acuña: Conceptualización, Metodología, Software, Análisis formal, Investigación, Curación de datos, Redacción – borrador original, Redacción – revisión y edición, Visualización.

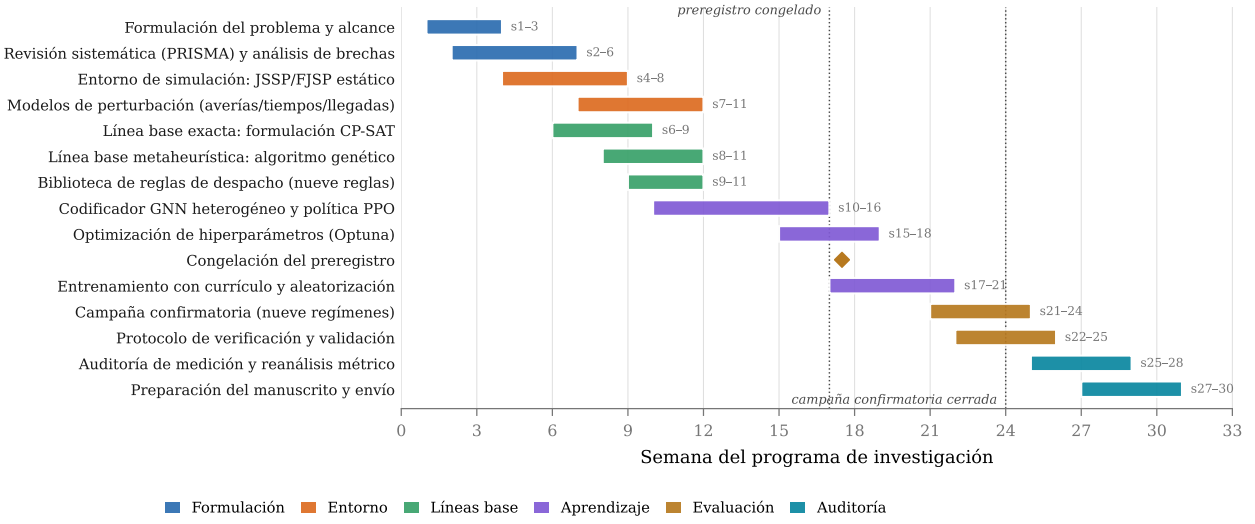


Figura 6: Cronograma del programa de investigación. El rombo marca la congelación del preregistro, tras la cual no se alteró hipótesis, umbral, conjunto de instancias ni prueba estadística alguna. La auditoría de medición y el reanálisis aquí reportados ocupan la fase final y son posteriores a esa congelación.

Referencias

Agarwal, R., Schwarzer, M., Castro, P.S., Courville, A., Bellemare, M.G., 2021. Deep reinforcement learning at the edge of the statistical precipice. Advances in Neural Information Processing Systems 34, 29304–29320.

Akiba, T., Sano, S., Yanase, T., Ohta, T., Koyama, M., 2019. Optuna: A next-generation hyperparameter optimization framework, in: Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, pp. 2623–2631. doi:10.1145/3292500.3330701.

Artzner, P., Delbaen, F., Eber, J.M., Heath, D., 1999. Coherent measures of risk. Mathematical Finance 9, 203–228. doi:10.1111/1467-9965.00068.

Aytug, H., Lawley, M.A., McKay, K., Mohan, S., Uzsoy, R., 2005. Executing production schedules in the face of uncertainties: A review and some future directions. European Journal of Operational Research 161, 86–110. doi:10.1016/j.ejor.2003.08.027.

Bengio, Y., Lodi, A., Prouvost, A., 2021. Machine learning for combinatorial optimization: A methodological tour d'horizon. European Journal of Operational Research 290, 405–421. doi:10.1016/j.ejor.2020.07.063.

Demšar, J., 2006. Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research 7, 1–30.

Fisher, H., Thompson, G.L., 1963. Probabilistic learning combinations of local job-shop scheduling rules. Prentice Hall, Englewood Cliffs, NJ.

García, S., Herrera, F., 2008. An extension on "statistical comparisons of classifiers over multiple data sets" for all pairwise comparisons. Journal of Machine Learning Research 9, 2677–2694.

Goren, S., Sabuncuoglu, I., 2008. Robustness and stability measures for scheduling: single-machine environment. IIE Transactions 40, 66–83. doi:10.1080/07408170701283198.

Haupt, R., 1989. A survey of priority rule-based scheduling. OR Spektrum 11, 3–16. doi:10.1007/BF01721162.

Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., Meger, D., 2018. Deep reinforcement learning that matters. Proceedings of the AAAI Conference on Artificial Intelligence 32. doi:10.1609/aaai.v32i1.11694.

Herroelen, W., Leus, R., 2005. Project scheduling under uncertainty: Survey and research potentials. European Journal of Operational Research 165, 289–306. doi:10.1016/j.ejor.2004.04.002.

Holthaus, O., Rajendran, C., 1997. Efficient dispatching rules for scheduling in a job shop. International Journal of Production Economics 48, 87–105. doi:10.1016/S0925-5273(96)00068-0.

Huang, Y., Ye, X., Yang, Z., 2025. Deep reinforcement learning for machine scheduling: Methodology, the state-of-the-art, and future directions. Computers & Industrial Engineering 200, 110856. doi:10.1016/j.cie.2025.110856.

Kayhan, B.M., Yildiz, G., 2023. Reinforcement learning applications to machine scheduling problems: a comprehensive literature review. Journal of Intelligent Manufacturing 34, 905–929. doi:10.1007/s10845-021-01847-3.

Kerr, N.L., 1998. HARKing: Hypothesizing after the results are known. Personality and Social Psychology Review 2, 196–217. doi:10.1207/s15327957pspr0203_4.

Lawrence, S., 1984. Resource constrained project scheduling: an experimental investigation of heuristic scheduling techniques. Graduate School of Industrial Administration, Carnegie-Mellon University .

Leon, V.J., Wu, S.D., Storer, R.H., 1994. Robustness measures and robust scheduling for job shops. IIE Transactions 26, 32–43. doi:10.1080/07408179408966626.

Mehta, S.V., Uzsoy, R.M., 1998. Predictable scheduling of a job shop subject to breakdowns. IEEE Transactions on Robotics and Automation 14, 365–378. doi:10.1109/70.678447.

Munafò, M.R., Nosek, B.A., Bishop, D.V.M., Button, K.S., Chambers, C.D., Percie du Sert, N., Simonsohn, U., Wagenmakers, E.J., Ware, J.J., Ioannidis, J.P.A., 2017. A manifesto for reproducible science. Nature Human Behaviour 1, 0021. doi:10.1038/s41562-016-0021.

Ouelhadj, D., Petrovic, S., 2009. A survey of dynamic scheduling in manufacturing systems. Journal of Scheduling 12, 417–431. doi:10.1007/s10951-008-0090-8.

Park, J., Chun, J., Kim, S.H., Kim, Y., Park, J., 2021. Learning to schedule job-shop problems: representation and policy learning using graph neural network and reinforcement learning. International Journal of Production Research 59, 3360–3377. doi:10.1080/00207543.2020.1870013.

Perron, L., Furnon, V., 2024. OR-Tools. Google. https://developers.google.com/optimization/.

Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., Dormann, N., 2021. Stable-baselines3: Reliable reinforcement learning implementations. Journal of Machine Learning Research 22, 1–8.

Rockafellar, R.T., Uryasev, S., 2000. Optimization of conditional value-at-risk. Journal of Risk 2, 21–41. doi:10.21314/JOR.2000.038.

Sabuncuoglu, I., Bayiz, M., 2000. Analysis of reactive scheduling problems in a job shop environment. European Journal of Operational Research 126, 567–586. doi:10.1016/S0377-2217(99)00311-2.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O., 2017. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347 .

Smit, I., Zhou, C., Bekker, J., 2025. Reinforcement learning in dynamic job shop scheduling: a comprehensive review of AI-driven approaches in modern manufacturing. Journal of Intelligent Manufacturing doi:10.1007/s10845-025-02585-6.

Song, W., Chen, X., Li, Q., Cao, Z., 2023. Flexible job-shop scheduling via graph neural network and deep reinforcement learning. IEEE Transactions on Industrial Informatics 19, 1600–1610. doi:10.1109/TII.2022.3189725.

Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., Abbeel, P., 2017. Domain randomization for transferring deep neural networks from simulation to the real world, in: IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pp. 23–30. doi:10.1109/IROS.2017.8202133.

Xu, K., Hu, W., Leskovec, J., Jegelka, S., 2019. How powerful are graph neural networks?, in: International Conference on Learning Representations (ICLR).

Xu, M., Mei, Y., Zhang, F., Zhang, M., 2025. Learn to optimise for job shop scheduling: a survey with comparison between genetic programming and reinforcement learning. Artificial Intelligence Review 58, 32. doi:10.1007/s10462-024-11059-9.

Zhang, C., Song, W., Cao, Z., Zhang, J., Tan, P.S., Xu, C., 2020. Learning to dispatch for job shop scheduling via deep reinforcement learning, in: Advances in Neural Information Processing Systems (NeurIPS), pp. 1621–1632.